

**Optimasi dan Interpretasi Prediksi Risiko Stroke
Menggunakan Stacking Ensemble Learning dan SHAP
pada Data Kesehatan Tidak Seimbang
Proposal Tugas Akhir**

Kelas MK Penulisan Proposal (CCH4A3)

**103062300102
Stiefanny Dwi Chandra**



**Program Studi Sarjana Teknologi Informasi
Fakultas Informatika
Universitas Telkom
Jakarta
2026**

Lembar Persetujuan

**Optimasi dan Interpretasi Prediksi Risiko Stroke Menggunakan
Stacking Ensemble Learning dan SHAP pada Data Kesehatan
Tidak Seimbang**

**Optimization and Interpretation of Stroke Risk Prediction Using
Stacking Ensemble Learning and SHAP on Imbalanced Health
Data**

**NIM :103062300102
Stiefanny Dwi Chandra**

Proposal ini diajukan sebagai usulan pembuatan tugas akhir pada
Program Studi Sarjana Teknologi Informasi
Fakultas Informatika Universitas Telkom

Jakarta, 4 Juni 2026
Menyetujui

Calon Pembimbing 1

Calon Pembimbing 2

Nurul Ilmi, S.Kom., M.T.
25930029

Achmad Udin Zailani, S.Kom., M.Kom.
25830001

DAFTAR ISI

ABSTRAK	4
1. PENDAHULUAN	5
1.1 Latar Belakang	5
1.2 Perumusan Masalah	6
1.3 Tujuan	7
1.4 Batasan Masalah	7
1.5 Hipotesis	8
1.6 Rencana Kegiatan	8
1.7 Jadwal Kegiatan	10
2. KAJIAN PUSTAKA	11
2.1 Penelitian Terdahulu	11
2.1.1 Stroke Detection Through Ensemble Learning: A Stacking Approach	11
2.1.2 Predicting Stroke Occurrences: A Stacked Machine Learning Approach with Feature Selection and Data Preprocessing	11
2.1.3 Stacking Ensemble Learning Model to Predict 6-Month Mortality in Ischemic Stroke Patients	12
2.1.4 Explainable Artificial Intelligence for Stroke Prediction through Comparison of Deep Learning and Machine Learning Models	12
2.1.5 Threshold Moving Approaches for Addressing the Class Imbalance Problem and Their Application to Multi-label Classification	13
2.1.6 Analisis Penelitian Terdahulu	13
2.1.7 Posisi Penelitian (<i>Research Gap</i>)	18
2.2. Landasan Teori	18
2.2.1 Stroke	18
2.2.2 Prediksi Stroke Menggunakan Machine Learning	19
2.2.3 Karakteristik Dataset Medis dan Class Imbalance	19
2.2.4 Synthetic Minority Oversampling Technique (SMOTE)	19
2.2.5 Data Splitting	20
2.2.6 Pipeline Preprocessing	20
2.2.7 Random Forest	21
2.2.8 Gradient Boosting Ensemble	21
2.2.8.1 Extreme Gradient Boosting (XGBoost)	22

2.2.8.2 Light Gradient Boosting Machine (LightGBM).....	22
2.2.8.3 Categorical Boosting (CatBoost).....	23
2.2.9 Stacking Ensemble Learning	23
2.2.10 Out-of-Fold (OOF) Prediction pada Stacking Ensemble.....	24
2.2.11 Stratified K-Fold Cross Validation	25
2.2.12 Threshold Optimization	25
2.2.13 Explainable Artificial Intelligence (SHAP).....	26
2.2.14 Evaluasi Performa Model	27
3. PERANCANGAN SISTEM	29
3.1 Metodologi Penelitian	29
3.2 Sumber dan Karakteristik Data	29
3.2.1 Sumber Dataset	29
3.2.2 Dimensi dan Struktur Data	29
3.2.3 Analisis Karakteristik Distribusi dan Ketimpangan Kelas (<i>Class Imbalance</i>)	31
3.3 Desain Sistem	31
3.4 Skenario dan Alur Sistem Prediksi.....	33
3.4.1 Fase 1. Eksplorasi dan Pemahaman Data (Exploratory Data Analysis).....	33
3.4.2 Fase 2. Persiapan Data (Data Preparation)	33
3.4.3 Fase 3. Pengembangan Model Prediksi (Model Development)	34
3.4.4 Fase 4. Threshold Optimization dan Evaluasi Model.....	35
3.4.5 Fase 5. Pengujian pada Hold-Out Test Set	35
3.4.6 Fase 6. Explainable Artificial Intelligence (SHAP).....	36
DAFTAR PUSTAKA	38

ABSTRAK

Stroke merupakan penyakit yang dapat menyebabkan gangguan fungsi tubuh, sehingga proses deteksi dini menggunakan pendekatan *machine learning* menjadi sangat krusial. Namun, pemodelan pada dataset medis sering terkendala masalah *class imbalance*, di mana model cenderung lebih dominan mempelajari kelas mayoritas sehingga berpotensi kurang optimal dalam mendeteksi kasus stroke. Penelitian ini bertujuan untuk mengembangkan rancangan model prediksi stroke menggunakan dataset Fedesoriano melalui pendekatan *Stacking Ensemble*. Tahapan penelitian yang direncanakan mencakup eksplorasi data, persiapan data, pembangunan model, optimasi *threshold*, evaluasi performa, serta interpretasi model. Sebagai upaya untuk menangani ketimpangan data, *Synthetic Minority Oversampling Technique* (SMOTE) akan diintegrasikan ke dalam *pipeline* pelatihan model dasar guna meminimalisir risiko *data leakage*. Selain itu, *class weighting* juga akan diterapkan pada *meta-learner* agar proses pelatihan dapat lebih terkontrol. Arsitektur model akan dibangun menggunakan *Random Forest* sebagai *baseline*, serta ansambel yang terdiri dari *XGBoost*, *LightGBM*, dan *CatBoost* sebagai *base learner*, yang dipadukan dengan *Logistic Regression* sebagai *meta-learner*. Tahap optimasi *threshold* akan difokuskan pada fungsi objektif *Recall* dan *F2-Score* sebagai upaya untuk memaksimalkan sensitivitas deteksi kelas minoritas. Kinerja model nantinya akan dievaluasi menggunakan metrik *Accuracy*, *Precision*, *Recall*, *Metric Gap*, *F1-Score*, *F2-Score*, *ROC-AUC*, dan *PR-AUC*. Untuk aspek transparansi, metode *SHAP* (*SHapley Additive exPlanations*) direncanakan untuk diimplementasikan melalui rancangan *Dual-Layer SHAP Framework*. Kerangka kerja ini mencakup rencana interpretasi algoritmik pada *meta-learner* untuk kebutuhan validasi arsitektur, serta interpretasi klinis melalui analisis global dan lokal. Melalui tahapan tersebut, penelitian ini diharapkan dapat menghasilkan model prediksi stroke yang lebih adaptif terhadap ketidakseimbangan data, sekaligus mampu memberikan penjelasan keputusan yang lebih transparan secara teknis maupun klinis.

Kata kunci: Stroke Prediction, Stacking Ensemble, SMOTE, Threshold Optimization, F2-Score, SHAP

1. PENDAHULUAN

1.1 Latar Belakang

Stroke merupakan salah satu penyakit yang memiliki dampak serius terhadap kesehatan karena dapat menyebabkan gangguan fungsi otak akibat adanya penyumbatan atau pecahnya pembuluh darah. Proses identifikasi risiko stroke menjadi penting karena faktor yang berhubungan dengan kejadian stroke dapat berasal dari kombinasi berbagai karakteristik pasien. Perkembangan machine learning memberikan pendekatan yang dapat digunakan untuk mempelajari pola dari data kesehatan dan menghasilkan prediksi berdasarkan hubungan antar variabel yang tersedia [1].

Dalam penerapan machine learning pada bidang kesehatan, data yang digunakan sering memiliki distribusi kelas yang tidak seimbang. Kondisi tersebut terjadi ketika jumlah sampel pada kelas tertentu jauh lebih sedikit dibandingkan kelas lainnya, sehingga model dapat lebih dominan mempelajari kelas mayoritas. Permasalahan ini dapat menyebabkan kemampuan model dalam mengenali kasus minoritas seperti pasien stroke menjadi kurang optimal [2].

Salah satu pendekatan yang dapat digunakan untuk menangani permasalahan ketidakseimbangan kelas adalah Synthetic Minority Oversampling Technique (SMOTE) [3]. Metode ini bekerja dengan membuat data sintesis baru pada kelas minoritas berdasarkan pola kedekatan antar data sehingga distribusi kelas menjadi lebih seimbang. Selain itu, strategi pembobotan kelas juga dapat diterapkan untuk memberikan penalti yang berbeda terhadap kesalahan klasifikasi pada masing-masing kelas.

Selain permasalahan imbalance, pemilihan model juga menjadi faktor penting dalam pengembangan sistem prediksi stroke. Penggunaan satu algoritma terkadang memiliki keterbatasan dalam menangkap pola kompleks pada data kesehatan. Pendekatan ensemble learning melalui metode stacking dapat menggabungkan beberapa model pembelajaran mesin sehingga menghasilkan representasi prediksi yang berasal dari beberapa karakteristik algoritma [4].

Beberapa penelitian menunjukkan bahwa pendekatan ensemble dapat diterapkan pada prediksi stroke dengan mengombinasikan beberapa algoritma klasifikasi [5]. Penggunaan beberapa model dasar memungkinkan model akhir memperoleh informasi prediksi yang lebih beragam dibandingkan hanya menggunakan satu algoritma. Hal tersebut menjadikan ensemble learning menjadi salah satu pendekatan yang banyak digunakan dalam penelitian prediksi berbasis data medis.

Penelitian lain juga menunjukkan bahwa stacked ensemble classifier dapat digunakan untuk meningkatkan kemampuan klasifikasi pada permasalahan kesehatan. Dalam metode stacking, keluaran probabilitas dari beberapa model dasar digunakan sebagai masukan bagi model penggabung sehingga keputusan akhir tidak hanya bergantung pada satu algoritma tertentu [6].

Pada data kesehatan berbentuk tabular, model berbasis decision tree ensemble sering digunakan karena mampu menangani hubungan non-linear antar fitur [7]. Algoritma berbasis pohon keputusan dapat mempelajari pola kompleks tanpa memerlukan asumsi hubungan linear antar variabel sehingga sesuai digunakan pada dataset dengan kombinasi fitur numerik dan kategorikal.

Selain performa prediksi, aspek kepercayaan terhadap model juga menjadi perhatian dalam penerapan machine learning pada bidang kesehatan. Model prediksi perlu dianalisis tidak hanya berdasarkan hasil evaluasi numerik, tetapi juga melalui pemahaman mengenai alasan model menghasilkan suatu keputusan. Oleh karena itu, pendekatan interpretasi model diperlukan agar hasil prediksi dapat dianalisis dengan lebih baik. [8] Berdasarkan uraian tersebut, masih terdapat kebutuhan untuk mengembangkan model prediksi stroke yang mampu menangani permasalahan ketidakseimbangan kelas, memanfaatkan kombinasi beberapa algoritma, serta memberikan interpretasi terhadap hasil prediksi. Penelitian ini mengusulkan pendekatan stacking ensemble menggunakan XGBoost, LightGBM, dan CatBoost dengan penerapan SMOTE, class weighting, serta optimasi threshold berbasis F2-score untuk meningkatkan kemampuan model dalam mendeteksi kelas stroke pada data tidak seimbang. Selain itu, analisis SHAP digunakan untuk mengetahui kontribusi fitur terhadap keputusan model.

1.2 Perumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, pengembangan model prediksi risiko stroke masih menghadapi beberapa tantangan, terutama terkait karakteristik data kesehatan yang tidak seimbang, kebutuhan peningkatan kemampuan deteksi terhadap individu berisiko, serta pentingnya interpretasi hasil prediksi dalam mendukung pengambilan keputusan di bidang kesehatan. Oleh karena itu, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membangun arsitektur *Stacking Ensemble* (XGBoost, LightGBM, CatBoost) yang terisolasi dari kebocoran data (*zero-leakage*) dan membandingkan performanya dengan model *baseline* (Random Forest) pada prediksi risiko stroke?
2. Bagaimana pengaruh kombinasi *Pipeline SMOTE* dan *Threshold Optimization* berbasis F2-Score terhadap peningkatan kemampuan model dalam mendeteksi kelas minoritas (pasien stroke)?

3. Bagaimana menguraikan proses pengambilan keputusan model secara transparan menggunakan metode SHAP pada level *ensemble* (Meta-Learner) dan level klinis (Model Dominan)?

1.3 Tujuan

Berdasarkan rumusan masalah yang telah ditetapkan, penelitian ini bertujuan untuk mengembangkan pendekatan prediksi risiko stroke yang mampu memberikan performa prediksi yang baik sekaligus menghasilkan interpretasi yang dapat dipahami. Adapun tujuan penelitian ini adalah sebagai berikut:

1. Membangun dan mengevaluasi arsitektur *Stacking Ensemble* yang bebas kebocoran data (*zero-leakage*) serta membandingkan signifikansi performanya terhadap model *baseline* (Random Forest).
2. Menganalisis efektivitas penerapan Pipeline SMOTE dan Threshold Optimization berbasis F2-Score dalam meminimalkan kegagalan deteksi (False Negative) pada data yang sangat tidak seimbang, serta mengevaluasi *trade-off* yang terjadi antara tingkat *Recall* dan *Precision*.
3. Menjelaskan faktor-faktor yang memengaruhi hasil prediksi secara hierarkis menggunakan metode SHAP dua level, baik dari segi kontribusi algoritma pembentuk maupun faktor klinis pasien.

1.4 Batasan Masalah

Penelitian akan lebih terarah dan sesuai dengan tujuan yang ingin dicapai, jika batasan masalah ditentukan yang mencakup:

1. Penelitian ini menggunakan data sekunder *Stroke Prediction Dataset* yang dipublikasikan oleh fedesoriano dan diakses melalui platform Kaggle.
2. Permasalahan difokuskan pada tugas klasifikasi biner untuk memprediksi kelas berisiko stroke dan kelas tidak berisiko stroke.
3. Algoritma Random Forest secara eksklusif digunakan sebagai model *baseline* pembanding, sedangkan arsitektur *Stacking Ensemble* dibangun menggunakan XGBoost, LightGBM, dan CatBoost sebagai *base learners*, serta Logistic Regression sebagai *meta-learner*.
4. Penanganan ketidakseimbangan kelas (*class imbalance*) menggunakan SMOTE dilakukan secara ketat di dalam *Pipeline* pelatihan (*cross-validation*) untuk menjamin tidak terjadinya kebocoran data (*data leakage*).
5. Batas keputusan prediksi (*decision boundary*) tidak menggunakan nilai *default*, melainkan dicari secara matematis melalui *Threshold Optimization* dengan target maksimasi nilai F2-Score.

6. Evaluasi model dilakukan menggunakan metrik *Accuracy*, *Precision*, *Recall*, *F1-Score*, *F2-Score*, *ROC-AUC*, dan *PR-AUC*.
7. Interpretasi model dilakukan menggunakan metode SHAP dengan pendekatan dua level: level *ensemble* untuk melihat kontribusi model dasar, dan level klinis untuk melihat kontribusi fitur pasien (Global dan Lokal).
8. Penelitian ini dibatasi pada tahap pemodelan analitik preskriptif dan tidak mencakup implementasi sistem klinis langsung maupun pengembangan aplikasi perangkat lunak.

1.5 Hipotesis

1. **H1:** Penerapan metode Stacking Ensemble mampu menghasilkan performa prediksi stroke yang lebih baik dibandingkan model tunggal Random Forest sebagai baseline berdasarkan evaluasi menggunakan metrik Recall, F1-Score, F2-Score, ROC-AUC, dan PR-AUC.
2. **H2:** Penerapan strategi penanganan ketidakseimbangan kelas menggunakan *Synthetic Minority Over-sampling Technique* (SMOTE) di dalam *Pipeline* yang dikombinasikan dengan pendekatan optimasi ambang batas (*threshold optimization*) mampu meningkatkan kemampuan model dalam mengenali kelas minoritas pada prediksi stroke.
3. **H3:** Penerapan metode *Explainable Artificial Intelligence* (XAI) menggunakan SHAP pada arsitektur *Stacking Ensemble* mampu menguraikan keputusan prediksi secara transparan melalui analisis level *ensemble* dan level klinis yang mencakup interpretasi *Global*, arah pengaruh pada fitur terbaik (*Dependence*), serta penjelasan risiko pada kasus individu (*Local*).

1.6 Rencana Kegiatan

Pelaksanaan penelitian dilakukan melalui serangkaian tahapan yang saling berkaitan untuk mencapai tujuan penelitian yang telah ditetapkan. Setiap tahapan dirancang secara sistematis mulai dari studi literatur, pengolahan data, pengembangan model, evaluasi hasil, interpretasi model, hingga penyusunan laporan akhir. Rencana kegiatan penelitian yang akan dilaksanakan disajikan sebagai berikut.

1. **Fase 1. Studi Literatur:** Pada tahap ini dilakukan pengumpulan dan kajian berbagai referensi ilmiah yang berkaitan dengan prediksi stroke menggunakan machine learning, metode Stacking Ensemble, penanganan data tidak seimbang, optimasi threshold, serta Explainable Artificial Intelligence (XAI). Studi literatur digunakan sebagai dasar dalam menentukan metode, rancangan eksperimen, dan evaluasi penelitian.

2. **Fase 2. Eksplorasi dan Pemahaman Data (Exploratory Data Analysis):** Tahap ini dilakukan untuk memahami karakteristik dataset stroke yang digunakan. Proses eksplorasi meliputi pemeriksaan struktur dataset, identifikasi missing value, analisis distribusi kelas, serta analisis karakteristik fitur numerik dan kategorikal. Tahap ini bertujuan untuk mengetahui kondisi awal data sebelum dilakukan proses pemodelan.
3. **Fase 3. Persiapan Data (Data Preparation):** Tahap persiapan data dilakukan dengan membagi dataset menjadi data training dan data testing menggunakan metode stratified split untuk mempertahankan distribusi kelas. Selanjutnya dilakukan preprocessing yang meliputi:
 - Imputasi missing value,
 - Standarisasi fitur numerik,
 - Encoding fitur kategorikal.

Penanganan ketidakseimbangan kelas dilakukan menggunakan metode SMOTE yang diterapkan melalui pipeline sehingga proses oversampling hanya dilakukan pada data training dan setiap fold pelatihan untuk mencegah terjadinya data leakage.
4. **Fase 4. Pengembangan Model Prediksi (Model Development)** Pembangunan arsitektur model meliputi:
 - **Model Baseline:** *Random Forest* sebagai tolok ukur performa model tunggal.
 - **Base Learners:** *XGBoost*, *LightGBM*, dan *CatBoost* yang telah dioptimasi menggunakan *RandomizedSearch*.
 - **Meta-Learner:** *Logistic Regression* dengan penerapan class weight sebagai strategi penanganan *imbalance* pada level *meta-learner* untuk menjaga proses pelatihan tetap terkontrol.
5. **Fase 5. Optimasi Threshold dan Evaluasi Model:** Menggunakan *Stratified K-Fold Cross-Validation* untuk menghasilkan prediksi *Out-of-Fold* (OOF). Prediksi OOF digunakan sebagai *input* bagi *meta-learner* dalam membangun model *stacking*. Dilakukan optimasi *threshold* berbasis fungsi objektif **F2-Score** untuk mendapatkan titik potong probabilitas yang optimal. Evaluasi dilakukan menggunakan metrik: *Accuracy*, *Precision*, *Recall*, *F1-Score*, *F2-Score*, *ROC-AUC*, dan *PR-AUC*.
6. **Fase 6. Pengujian Hold-Out Test Set:** Tahap ini dilakukan dengan menguji model yang telah dilatih menggunakan data testing yang tidak digunakan selama proses pelatihan. Pengujian bertujuan untuk mengetahui kemampuan generalisasi model terhadap data baru.
7. **Fase 7. Explainable Artificial Intelligence (SHAP):** Tahap ini dilakukan untuk memberikan interpretasi terhadap model Stacking Ensemble sebagai model usulan penelitian. Interpretasi model dilakukan melalui *Dual-Layer SHAP Framework*:

- **Layer 1: Validasi Algoritmik (Analisis Meta-Learner):** Menggunakan *LinearExplainer* untuk membedah kontribusi probabilitas dari setiap *base learner* terhadap keputusan akhir *meta-learner*.
- **Layer 2: Validasi Klinis (Analisis Global & Lokal):** Menggunakan *KernelExplainer* untuk memberikan interpretasi global (pola fitur secara umum) dan interpretasi lokal (justifikasi medis untuk setiap pasien) agar hasil prediksi dapat dipercaya secara medis.

8. Fase 8. Analisis Hasil dan Penyusunan Laporan: Tahap akhir penelitian meliputi analisis hasil eksperimen, perbandingan performa Random Forest sebagai baseline dengan Stacking Ensemble, analisis hasil interpretasi SHAP, penyusunan kesimpulan, serta penyelesaian laporan tugas akhir.

1.7 Jadwal Kegiatan

Pengaturan waktu pelaksanaan penelitian diperlukan untuk memastikan setiap tahapan dapat diselesaikan sesuai dengan target yang telah ditentukan. Jadwal kegiatan penelitian disusun berdasarkan tahapan yang terdapat pada rencana kegiatan penelitian sehingga pelaksanaan penelitian dapat berlangsung secara terarah dan terukur. Jadwal pelaksanaan penelitian ditunjukkan pada Tabel 1.

Table 1 Jadwal Kegiatan

No	Kegiatan	Bulan 1	Bulan 2	Bulan 3	Bulan 4	Bulan 5
1	Studi Literatur					
2	Eksplorasi dan Pemahaman Dataset (EDA)					
3	Persiapan Data (Data Preparation)					
4	Pengembangan Model Prediksi (Model Development)					
5	Optimasi Threshold dan Evaluasi Model					
6	Pengujian Hold-Out Test Set					
7	Explainable Artificial Intelligence (SHAP)					
8	Analisis Hasil dan Penyusunan Laporan					

2. KAJIAN PUSTAKA

Penelitian terdahulu merupakan kajian terhadap berbagai penelitian yang relevan dengan topik yang diteliti. Kajian ini bertujuan untuk mengetahui perkembangan penelitian mengenai prediksi stroke menggunakan machine learning, mengidentifikasi metode yang telah digunakan, serta menemukan celah penelitian (research gap) yang dapat menjadi dasar pengembangan penelitian ini. Selain itu, penelitian terdahulu digunakan sebagai acuan dalam menentukan metode, teknik evaluasi, serta pendekatan interpretabilitas yang sesuai dengan tujuan penelitian.

2.1 Penelitian Terdahulu

2.1.1 Stroke Detection Through Ensemble Learning: A Stacking Approach

Penelitian yang dilakukan oleh [1] mengusulkan metode *stacking ensemble* untuk mendeteksi risiko stroke dengan mengombinasikan beberapa model klasifikasi. Penelitian tersebut membuktikan bahwa pendekatan *ensemble* mampu menghasilkan performa yang lebih unggul dibandingkan model tunggal karena dapat memanfaatkan keberagaman informasi dalam menangkap pola data klinis yang kompleks. Meskipun demikian, arsitektur yang diusulkan masih memiliki keterbatasan, yaitu belum mengintegrasikan *Explainable Artificial Intelligence* (XAI) untuk transparansi keputusan, belum menerapkan *threshold optimization*, serta rentan terhadap kebocoran data (*data leakage*) jika penanganan data tidak seimbang dilakukan di luar proses validasi. Oleh karena itu, penelitian ini mengembangkan pendekatan serupa dengan memastikan *zero data leakage* melalui penerapan *Pipeline*, serta menambahkan *threshold optimization* dan interpretasi model menggunakan SHAP agar prediksi yang dihasilkan tidak hanya optimal, tetapi juga dapat dijelaskan secara medis.

2.1.2 Predicting Stroke Occurrences: A Stacked Machine Learning Approach with Feature Selection and Data Preprocessing

Penelitian oleh [6] menerapkan metode *stacking* untuk memprediksi kejadian stroke dengan fokus utama pada tahapan *data preprocessing* dan *feature selection*. Hasil penelitian menunjukkan bahwa penyiapan data yang ketat sangat signifikan dalam meningkatkan akurasi prediksi model gabungan. Namun, penelitian tersebut hanya mengevaluasi performa menggunakan metrik umum (Akurasi) dan mengabaikan penanganan ketidakseimbangan kelas (*class imbalance*), sehingga tidak diketahui sensitivitas model terhadap pasien stroke yang sebenarnya (kelas minoritas). Pada penelitian ini, fokus diarahkan untuk menutup celah tersebut melalui penerapan algoritma *Synthetic Minority Over-sampling*

Technique (SMOTE) secara terisolasi di dalam *Pipeline*, serta melakukan *threshold optimization* yang secara spesifik menargetkan metrik *Recall* dan *F2-Score* guna meminimalkan kegagalan deteksi pasien berisiko.

2.1.3 Stacking Ensemble Learning Model to Predict 6-Month Mortality in Ischemic Stroke Patients

Penelitian yang dilakukan oleh [9] memanfaatkan *stacking ensemble* untuk memprediksi mortalitas pasien stroke iskemik dalam periode enam bulan setelah serangan. Penelitian tersebut menjadi landasan kuat yang membuktikan bahwa arsitektur *ensemble* sangat andal dan memiliki kemampuan prediksi yang baik ketika diimplementasikan pada skenario data medis sungguhan di rumah sakit. Meskipun memiliki domain serebrovaskular yang sama, penelitian tersebut berfokus pada analisis pasca-stroke (mortalitas) dan belum menyentuh permasalahan *class imbalance* maupun transparansi hasil prediksi. Oleh karena itu, penelitian ini mengadaptasi keandalan komputasi dari konsep *stacking ensemble* untuk skenario prediksi (deteksi dini), dengan mengekspansi metodenya melalui strategi optimasi ambang batas keputusan dan pendekatan *explainability* menggunakan SHAP.

2.1.4 Explainable Artificial Intelligence for Stroke Prediction through Comparison of Deep Learning and Machine Learning Models

Penelitian oleh [10] membandingkan berbagai model *Machine Learning* tunggal untuk prediksi stroke dan mengaplikasikan *Explainable Artificial Intelligence* (SHAP) untuk menguraikan hasil prediksi. Penelitian tersebut sangat relevan karena menegaskan bahwa interpretabilitas model adalah syarat mutlak dalam bidang kesehatan untuk membangun kepercayaan (*trust*) pengguna terhadap sistem pendukung keputusan. Namun demikian, penelitian tersebut hanya menerapkan SHAP pada model tunggal dan tidak mengeksplorasi penerapannya pada arsitektur agregasi seperti *stacking ensemble*. Untuk melengkapi keterbatasan tersebut, penelitian ini mengusulkan integrasi SHAP dengan pendekatan Dua Level, yaitu interpretasi pada level *ensemble* (Meta-Learner) untuk menganalisis kontribusi model dasar, dan level klinis (Model Dominan) untuk mengekstrak faktor risiko pasien secara menyeluruh melalui interpretasi Global, analisis arah pengaruh fitur terbaik (Dependence), serta penjelasan risiko pada kasus individu (Local).

2.1.5 Threshold Moving Approaches for Addressing the Class Imbalance Problem and Their Application to Multi-label Classification

Penelitian oleh [11] membahas pendekatan *threshold moving* (pergeseran ambang batas) sebagai salah satu strategi algoritmik untuk mengatasi permasalahan *class imbalance*. Penelitian tersebut membuktikan secara matematis bahwa penggunaan batas keputusan (*threshold*) default sebesar 0,5 sering kali berakibat fatal dan tidak menghasilkan performa terbaik pada data yang timpang. Penyesuaian *threshold* terbukti krusial untuk meningkatkan sensitivitas deteksi kelas minoritas. Meskipun penelitian tersebut bersifat umum dan tidak dikhususkan untuk prediksi stroke maupun metode *stacking*, landasan teoretisnya menjadi fondasi penting bagi penelitian ini. Melalui pendekatan **Threshold Optimization**, penelitian ini berupaya mencari batas keputusan optimal berbasis maksimasi nilai *F2-Score* pada hasil *cross-validation* guna meminimalkan *False Negative* pada diagnosis risiko stroke.

2.1.6 Analisis Penelitian Terdahulu

Berdasarkan berbagai kajian penelitian terdahulu, metode *stacking ensemble* terbukti mampu memberikan performa prediksi yang superior pada kasus stroke maupun permasalahan medis klinis lainnya. Penggunaan *Explainable Artificial Intelligence* (XAI) juga mulai diadaptasi secara luas untuk meningkatkan transparansi sistem pendukung keputusan di bidang kesehatan. Namun, masih terdapat celah penelitian yang signifikan, seperti rentannya model terhadap kebocoran data (*data leakage*) akibat penanganan *class imbalance* yang tidak terisolasi, penggunaan ambang batas keputusan (*threshold*) default yang mengabaikan sensitivitas deteksi kelas minoritas, serta penerapan interpretasi SHAP yang umumnya hanya terbatas pada model klasifikasi tunggal.

Oleh karena itu, penelitian ini mengusulkan pengembangan arsitektur *Stacking Ensemble* menggunakan XGBoost, LightGBM, dan CatBoost sebagai *base learners*, serta Logistic Regression sebagai *meta-learner*. Kebaruan (*novelty*) dari penelitian ini terletak pada integrasi penanganan ketidakseimbangan data yang bebas bocor (*zero-leakage*) melalui algoritma SMOTE di dalam *Pipeline* pelatihan, yang dipadukan dengan pembobotan kelas (*class weighting*). Kemampuan deteksi kasus stroke dioptimalkan secara matematis melalui pendekatan *Threshold Optimization* dengan memaksimalkan fungsi objektif *F2-Score*. Selain itu, transparansi keputusan model diuraikan secara komprehensif menggunakan pendekatan SHAP Dua Level (*level ensemble* dan *level klinis*). Pendekatan *end-to-end* ini diharapkan mampu menghasilkan model prediksi yang sangat sensitif, stabil secara statistik, serta dapat dijelaskan secara rinci kepada pengguna di bidang kesehatan.

Berikut adalah rangkuman visual dari literatur-literatur kunci yang menjadi landasan utama dalam penelitian ini:

Table 2 Matriks Tinjauan Pustaka

Pustak a Utama	Judul dan Sumber Dataset	Rumusan Masalah	Tujuan / Ide Pokok	Algoritma	Kelebihan Penelitian	Kekurangan dan Keterbatasan (Gap)	Relasi dengan Topik Tugas Akhir
[1]	Stroke Detection Through Ensemble Learning: A Stacking Approach (Dataset prediksi stroke)	Bagaimana meningkatkan akurasi deteksi stroke dibandingkan model tunggal?	Mengembangkan model <i>stacking ensemble</i> untuk meningkatkan performa deteksi stroke.	<i>Stacking Ensemble</i>	Menunjukkan bahwa <i>stacking</i> mampu mengungguli klasifikasi model tunggal.	Belum menerapkan <i>Explainable AI</i> (SHAP), <i>threshold optimization</i> , serta rentan terhadap <i>data leakage</i> karena tidak menggunakan <i>pipeline</i> khusus untuk <i>imbalance data</i> .	Menjadi acuan dasar efektivitas penerapan arsitektur <i>stacking ensemble</i> pada prediksi risiko stroke.
[6]	Predicting Stroke Occurrences: A Stacked Machine Learning	Bagaimana meningkatkan prediksi stroke	Meningkatkan performa prediksi stroke	<i>Stacking Ensemble</i>	Membuktikan signifikansi tahap	Evaluasi hanya berfokus pada Akurasi	Menjadi rujukan pentingnya

Pustaka a Utama	Judul dan Sumber Dataset	Rumusan Masalah	Tujuan / Ide Pokok	Algoritma	Kelebihan Penelitian	Kekurangan dan Keterbatasan (Gap)	Relasi dengan Topik Tugas Akhir
	Approach with Feature Selection and Data Preprocessing (Dataset stroke)	melalui <i>preprocessing</i> dan seleksi fitur?	menggunakan <i>stacking</i> berbasis <i>preprocessing</i> dan seleksi fitur.	+ <i>Feature Selection</i>	<i>preprocessing</i> dalam meningkatkan performa model.	umum, belum menangani ketimpangan kelas (<i>class imbalance</i>), serta ketiadaan optimasi ambang batas dan transparansi keputusan.	skema <i>preprocessi ng</i> data yang ketat sebelum menyuplai data ke model <i>stacking</i> .
[9]	Stacking Ensemble Learning Model to Predict 6-Month Mortality in Ischemic Stroke Patients (Data klinis pasien stroke iskemik)	Bagaimana memprediksi mortalitas pasien stroke iskemik menggunakan <i>ensemble learning</i> ?	Mengembangkan model <i>stacking</i> untuk memprediksi probabilitas kematian pasien stroke.	<i>Stacking Ensemble</i>	Membuktikan efektivitas dan keandalan metode <i>stacking</i> pada skenario medis klinis yang nyata.	Fokus hanya pada mortalitas pasca-stroke, tidak membahas <i>class imbalance</i> , <i>threshold optimization</i> , maupun	Menguatkan validitas bahwa <i>stacking ensemble</i> adalah metode yang diakui dan efektif untuk

Pustaka a Utama	Judul dan Sumber Dataset	Rumusan Masalah	Tujuan / Ide Pokok	Algoritma	Kelebihan Penelitian	Kekurangan dan Keterbatasan (Gap)	Relasi dengan Topik Tugas Akhir
						interpretabilitas faktor penentu prediksi.	permasalahan medis serebrovaskular.
[10]	Explainable Artificial Intelligence for Stroke Prediction through Comparison of Deep Learning and Machine Learning Models <i>(Dataset stroke)</i>	Bagaimana menghasilkan prediksi stroke yang dapat diinterpretasikan secara medis?	Membandingkan model prediksi stroke tunggal dan mengaplikasikan <i>Explainable AI</i> .	<i>Machine Learning, Deep Learning, SHAP</i>	Menekankan krusialnya interpretabilitas (<i>trust</i>) dalam sistem pendukung keputusan kesehatan.	Penerapan SHAP hanya pada model tunggal, tidak mengeksplorasi arsitektur agregasi (<i>stacking</i>), dan belum melakukan optimasi deteksi pada data <i>imbalanced</i> .	Menjadi landasan teori metode SHAP, yang dalam penelitian ini akan diekspansi menjadi pendekatan SHAP Dua Level pada model <i>stacking</i> .

Pustaka a Utama	Judul dan Sumber Dataset	Rumusan Masalah	Tujuan / Ide Pokok	Algoritma	Kelebihan Penelitian	Kekurangan dan Keterbatasan (Gap)	Relasi dengan Topik Tugas Akhir
[11]	Threshold Moving Approaches for Addressing the Class Imbalance Problem and Their Application to Multi-label Classification <i>(Dataset multi-label)</i>	Bagaimana meningkatkan deteksi kelas minoritas melalui penyesuaian <i>threshold</i> ?	Mengkaji efektivitas pergeseran matematis <i>threshold</i> dalam mengatasi <i>class imbalance</i> .	<i>Threshold Moving</i>	Menunjukkan pembuktian matematis bahwa <i>threshold default</i> 0,5 seringkali berakibat fatal pada data <i>imbalanced</i> .	Kajian bersifat umum pada klasifikasi <i>multi-label</i> , belum diuji pada kasus klasifikasi medis biner spesifik seperti prediksi stroke.	Menjadi justifikasi akademis utama dalam mengimple mentasikan Threshold Optimizati on berbasis <i>F2-Score</i> untuk memaksima lkan <i>Recall</i> .

2.1.7 Posisi Penelitian (*Research Gap*)

Berdasarkan kajian literatur, integrasi antara metode *ensemble learning*, penanganan *imbalance data*, dan *Explainable Artificial Intelligence* (XAI) telah banyak dieksplorasi dalam domain prediksi medis. Namun, sebagian besar penelitian terdahulu masih memiliki celah metodologis yang berpotensi menghasilkan evaluasi yang bias dan ilusi performa. Celah pertama adalah tingginya risiko kebocoran data (*data leakage*) akibat penerapan algoritma *oversampling* di luar prosedur *cross-validation*. Celah kedua adalah penggunaan nilai ambang batas (*decision threshold*) *default* sebesar 0,5 yang mengabaikan urgensi klinis, sehingga sering kali gagal meminimalkan *False Negative* pada kasus penyakit fatal seperti stroke. Selain itu, implementasi SHAP pada arsitektur *ensemble* bertingkat seperti *Stacking* umumnya masih bersifat superfisial dan tidak mendetailkan hierarki keputusannya. Oleh karena itu, penelitian ini mengambil posisi untuk tidak sekadar menggabungkan metode, melainkan menyelesaikan masalah-masalah metodologis tersebut secara terukur. Kontribusi utama penelitian ini berfokus pada:

- (1) Pembangunan arsitektur *Stacking Ensemble* dengan jaminan *zero-leakage* melalui isolasi SMOTE di dalam *Pipeline*.
- (2) Optimalisasi kemampuan deteksi kelas minoritas menggunakan *optimasi threshold* yang digerakkan oleh fungsi objektif F2-Score serta divalidasi melalui analisis *Precision-Recall Trade-off*; dan
- (3) Perancangan metode interpretasi SHAP Dua Level (Level *Meta* dan Level Klinis) untuk memberikan transparansi keputusan prediksi yang dapat dipertanggungjawabkan secara komputasional maupun medis.

2.2. Landasan Teori

2.2.1 Stroke

Stroke merupakan kondisi medis yang terjadi akibat gangguan aliran darah menuju otak sehingga menyebabkan jaringan otak mengalami kekurangan oksigen dan nutrisi. Kondisi tersebut dapat menyebabkan gangguan fungsi neurologis yang berlangsung secara tiba-tiba dan membutuhkan penanganan cepat. Faktor risiko stroke dapat berasal dari karakteristik individu maupun kondisi medis tertentu seperti usia, hipertensi, penyakit jantung, kadar glukosa, serta faktor gaya hidup. Karena adanya hubungan kompleks antara berbagai faktor tersebut, pendekatan berbasis data dapat digunakan untuk membantu proses identifikasi pola risiko stroke berdasarkan karakteristik pasien [1].

2.2.2 Prediksi Stroke Menggunakan Machine Learning

Machine Learning merupakan pendekatan komputasi yang memungkinkan sistem mempelajari pola dari data historis untuk melakukan prediksi terhadap data baru. Dalam bidang kesehatan, Machine Learning banyak digunakan untuk membantu proses analisis data medis karena mampu menangani hubungan kompleks antar variabel yang sulit dijelaskan menggunakan metode statistik konvensional. Pada permasalahan prediksi stroke, model Machine Learning digunakan untuk mempelajari hubungan antara fitur klinis pasien dengan kemungkinan terjadinya stroke [5].

2.2.3 Karakteristik Dataset Medis dan Class Imbalance

Permasalahan ketidakseimbangan kelas atau class imbalance merupakan kondisi ketika jumlah data pada satu kelas jauh lebih banyak dibandingkan kelas lainnya. Pada kasus medis, kelas minoritas sering kali merepresentasikan kondisi penyakit, sedangkan kelas mayoritas merepresentasikan kondisi normal [2]. Ketidakseimbangan tersebut dapat menyebabkan model lebih dominan mengenali kelas mayoritas sehingga kemampuan mendeteksi kasus positif menjadi kurang optimal. Oleh karena itu, diperlukan strategi khusus agar model tetap mampu mengenali pola pada kelas minoritas.

2.2.4 Synthetic Minority Oversampling Technique (SMOTE)

Synthetic Minority Oversampling Technique (SMOTE) merupakan metode oversampling yang digunakan untuk menangani permasalahan ketidakseimbangan kelas dengan membuat sampel sintetis baru pada kelas minoritas. Metode ini tidak hanya melakukan duplikasi data, tetapi membuat data baru berdasarkan hubungan antar sampel minoritas yang memiliki karakteristik serupa. Proses pembentukan data sintetis pada SMOTE dapat dituliskan sebagai:

$$x_{new} = x_i + \lambda(x_j - x_i)$$

Keterangan:

- x_{new} = data sintetis baru
- x_i = data minoritas awal
- x_j = data minoritas tetangga
- λ = nilai acak antara 0 sampai 1

Namun, penerapan SMOTE harus dilakukan secara hati-hati karena jika dilakukan sebelum pembagian data, data sintetis dapat masuk ke data pengujian sehingga menyebabkan evaluasi terlalu optimis. Oleh karena itu, penelitian ini menerapkan SMOTE secara terisolasi di dalam pipeline menggunakan pendekatan

framework Imbalanced-Learn (Imblearn) bersama preprocessing dan model. Dengan pendekatan tersebut, proses SMOTE hanya dilakukan pada data training setiap fold sehingga data pengujian tetap merepresentasikan kondisi asli [12].

2.2.5 Data Splitting

Data splitting membagi dataset menjadi data *training* untuk pelatihan dan data *testing* untuk pengujian. Penelitian ini menggunakan metode *hold-out* berskema *stratified splitting* agar proporsi kelas stroke dan non-stroke tetap seimbang [3]. Guna mencegah *data leakage*, pemisahan data uji dilakukan sebelum modifikasi apapun. Oleh karena itu, proses *preprocessing* dan *oversampling* hanya diterapkan pada data *training*, sehingga data *testing* tetap merepresentasikan kondisi asli untuk evaluasi akhir yang valid.

2.2.6 Pipeline Preprocessing

Tahap preprocessing merupakan proses persiapan data sebelum digunakan oleh model Machine Learning. Proses ini bertujuan untuk memastikan data memiliki format yang sesuai dan mengurangi kemungkinan gangguan selama proses pembelajaran. Tahapan preprocessing dalam penelitian ini mencakup penanganan missing value, normalisasi fitur numerik, serta transformasi fitur kategorikal. Pipeline digunakan untuk menggabungkan beberapa tahap preprocessing dan pemodelan dalam satu alur yang terstruktur. Dengan penggunaan pipeline, seluruh proses transformasi hanya dipelajari menggunakan data training sehingga dapat mengurangi risiko terjadinya data leakage ketika melakukan evaluasi model [13]. Pada penelitian ini, preprocessing dilakukan menggunakan beberapa tahapan:

1. Imputasi missing value: Missing value pada fitur numerik ditangani menggunakan median, sedangkan fitur kategorikal menggunakan nilai yang paling sering muncul (most frequent).
2. Standardisasi fitur numerik: Standardisasi dilakukan untuk menyamakan skala antar fitur menggunakan persamaan:

$$z = \frac{x - \mu}{\sigma}$$

Keterangan:

- z : nilai hasil standardisasi
- x : nilai asli fitur
- μ : rata-rata fitur
- σ : standar deviasi fitur

3. Encoding fitur kategorikal: Fitur kategorikal diubah menjadi bentuk numerik menggunakan teknik One-Hot Encoding agar dapat diproses oleh algoritma Machine Learning.

2.2.7 Random Forest

Random Forest merupakan metode ensemble berbasis decision tree yang membangun banyak pohon keputusan secara independen kemudian menggabungkan hasil prediksi dari seluruh pohon untuk memperoleh keputusan akhir. Random Forest menggunakan teknik *bootstrap sampling* dan pemilihan fitur secara acak sehingga mampu mengurangi risiko overfitting dibandingkan penggunaan satu decision tree. Pada proses klasifikasi, hasil prediksi akhir Random Forest ditentukan berdasarkan suara terbanyak dari seluruh pohon keputusan:

$$\hat{y} = \text{mode}\{h_1(x), h_2(x), \dots, h_n(x)\}$$

Keterangan:

- $\hat{y}$: hasil prediksi akhir
- $h_n(x)$: prediksi dari decision tree ke-n

Random Forest digunakan sebagai model pembanding (*baseline*) dalam penelitian ini karena merupakan metode ensemble yang stabil, mampu menangani data tabular, dan sering digunakan sebagai acuan awal sebelum membangun model ensemble yang lebih kompleks [7].

2.2.8 Gradient Boosting Ensemble

Gradient Boosting merupakan metode ensemble learning yang membangun model secara bertahap (*sequential*) dengan tujuan memperbaiki kesalahan prediksi dari model sebelumnya. Setiap model baru dibentuk berdasarkan residual atau kesalahan model sebelumnya sehingga prediksi akhir merupakan gabungan dari beberapa weak learner berupa decision tree. Secara umum bentuk model gradient boosting dapat dituliskan sebagai:

$$F_m(x) = F_{m-1}(x) + \eta h_m(x)$$

Keterangan:

- $F_m(x)$: model akhir pada iterasi ke-m
- $F_{m-1}(x)$: model sebelumnya
- $h_m(x)$: model baru (*weak learner*)
- η : learning rate

Pendekatan gradient boosting banyak digunakan pada data berbentuk tabel karena mampu menangkap hubungan non-linear antar fitur. Dalam penelitian ini digunakan tiga algoritma berbasis gradient boosting yaitu XGBoost, LightGBM, dan CatBoost sebagai base learner pada stacking ensemble [14].

2.2.8.1 Extreme Gradient Boosting (XGBoost)

Extreme Gradient Boosting (XGBoost) merupakan pengembangan dari gradient boosting dengan tambahan regularisasi untuk mengontrol kompleksitas model dan mengurangi kemungkinan overfitting. XGBoost membangun decision tree secara bertahap dengan meminimalkan fungsi objektif yang terdiri dari fungsi error dan penalti kompleksitas model. Fungsi objektif XGBoost dirumuskan sebagai:

$$Obj(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

Keterangan:

- $l(y_i, \hat{y}_i)$: fungsi loss antara nilai aktual dan prediksi
- f_k : decision tree ke-k
- $\Omega(f_k)$: regularisasi kompleksitas tree
- K : jumlah tree

Komponen regularisasi digunakan untuk membatasi kompleksitas pohon sehingga model lebih stabil terhadap data baru. XGBoost digunakan sebagai salah satu base learner karena mampu menghasilkan prediksi yang kuat pada dataset tabular dan dapat menangani hubungan kompleks antar variabel [14].

2.2.8.2 Light Gradient Boosting Machine (LightGBM)

Light Gradient Boosting Machine (LightGBM) merupakan algoritma gradient boosting yang dikembangkan untuk meningkatkan efisiensi proses pembelajaran. Berbeda dengan boosting tradisional yang melakukan pertumbuhan pohon secara level-wise, LightGBM menggunakan pendekatan *leaf-wise* dengan memilih daun yang memberikan pengurangan loss terbesar. Optimasi LightGBM bertujuan untuk meminimalkan fungsi loss:

$$L = \sum_{i=1}^n l(y_i, F(x_i))$$

Keterangan:

- L : total loss model

- y_i : nilai aktual data ke-i
- $F(x_i)$: hasil prediksi model

Pemilihan leaf berdasarkan nilai pengurangan loss membuat LightGBM mampu membangun model dengan lebih efisien. Dalam penelitian ini LightGBM digunakan sebagai base learner untuk memberikan variasi karakteristik model pada proses stacking ensemble [15].

2.2.8.3 Categorical Boosting (CatBoost)

CatBoost merupakan algoritma gradient boosting yang dikembangkan untuk menangani data dengan fitur kategorikal. CatBoost menggunakan pendekatan *ordered boosting* yang bertujuan mengurangi bias akibat penggunaan data yang sama dalam proses pembelajaran. Pada CatBoost, estimasi gradien dilakukan menggunakan urutan data tertentu sehingga mengurangi kemungkinan *prediction shift*. Secara umum pembaruan model CatBoost mengikuti konsep boosting:

$$F_m(x) = F_{m-1}(x) + \alpha h_m(x)$$

Keterangan:

- $F_m(x)$: model pada iterasi ke-m
- $F_{m-1}(x)$: model sebelumnya
- $h_m(x)$: tree baru
- α : learning rate

Keunggulan CatBoost adalah kemampuannya dalam mengolah fitur kategorikal dengan metode internal sehingga dapat menjaga informasi kategori selama proses pelatihan. Dalam penelitian ini CatBoost digunakan sebagai base learner tambahan untuk meningkatkan keberagaman model pada stacking ensemble [16].

2.2.9 Stacking Ensemble Learning

Stacking ensemble adalah metode pembelajaran dua tingkat yang menggabungkan prediksi dari beberapa model dasar (*base learner*) melalui model penggabung (*meta-learner*). Berbeda dengan *bagging* atau *boosting*, *stacking* menggunakan hasil probabilitas dari *base learner* sebagai fitur masukan baru bagi *meta-learner* guna menghasilkan prediksi akhir yang lebih stabil. Pada penelitian ini, tingkat pertama menggunakan XGBoost, LightGBM, dan CatBoost sebagai *base learner* yang unggul menangkap pola non-linear pada data tabular yang hasil

prediksinya dipelajari kembali pada tahap berikutnya [4]. Secara umum, proses stacking dapat direpresentasikan sebagai berikut:

$$Z_i = [f_1(X_i), f_2(X_i), \dots, f_k(X_i)]$$

Keterangan:

- X_i = data input ke-i
- $f_1, f_2, \dots, f_k$ = base learner
- Z_i = fitur baru hasil prediksi base learner

Selanjutnya meta-learner akan mempelajari hubungan antara hasil prediksi tersebut dengan label sebenarnya:

$$\hat{y} = g(Z)$$

Keterangan:

- g = fungsi meta-learner
- $\hat{y}$ = prediksi akhir model stacking

Penelitian ini menggunakan *Logistic Regression* berbasis pembobotan kelas (*class weighting*) sebagai *meta-learner* untuk menggabungkan probabilitas prediksi dari model-model dasar secara objektif tanpa bias kelas. Pendekatan *stacking* ini dipilih karena jauh lebih andal daripada algoritma tunggal dalam menangkap pola hubungan fitur yang kompleks dan non-linear pada data medis.

2.2.10 Out-of-Fold (OOF) Prediction pada Stacking Ensemble

Pada metode stacking ensemble, diperlukan prediksi dari base learner yang digunakan sebagai input bagi meta learner. Penggunaan prediksi langsung dari data training dapat menyebabkan informasi bocor (data leakage) karena model telah melihat data tersebut sebelumnya. OOF Prediction digunakan untuk menghasilkan prediksi terhadap data yang belum pernah dilihat oleh model selama proses pelatihan. Data training dibagi menjadi beberapa fold, kemudian setiap model dilatih pada sebagian fold dan menghasilkan prediksi pada fold yang tidak digunakan untuk pelatihan. Hasil prediksi OOF kemudian digunakan sebagai fitur baru untuk melatih meta learner:

$$Z = [P_1(X) \quad P_2(X) \quad \dots \quad P_n(X)]$$

Keterangan:

- Z : matriks fitur meta
- $P_n(X)$: probabilitas prediksi base learner ke-n

Penggunaan OOF Prediction membantu menghasilkan arsitektur stacking yang lebih valid karena meta learner belajar dari prediksi yang tidak berasal dari data yang sama saat model dasar dilatih [4].

2.2.11 Stratified K-Fold Cross Validation

Cross Validation merupakan teknik validasi yang digunakan untuk mengukur kemampuan generalisasi model dengan membagi data menjadi beberapa bagian (fold). Pada penelitian dengan dataset tidak seimbang, pembagian data perlu mempertahankan proporsi kelas agar setiap fold tetap memiliki distribusi kelas yang serupa. Stratified K-Fold Cross Validation merupakan metode validasi yang menjaga distribusi kelas pada setiap fold. Proses ini dilakukan dengan membagi dataset menjadi k bagian, kemudian model dilatih menggunakan k – 1 bagian dan diuji menggunakan satu bagian secara bergantian. Estimasi performa akhir diperoleh dari rata-rata hasil evaluasi seluruh fold:

$$\text{Score} = \frac{1}{k} \sum_{i=1}^k \text{Score}_i$$

Keterangan:

- Score_i : nilai evaluasi fold ke-i
- k: jumlah fold

Penelitian ini menerapkan *Stratified 5-Fold Cross Validation* untuk menghasilkan probabilitas *Out-of-Fold* (OOF) secara presisi [3]. Selain itu, pada tahap optimasi dan evaluasi akhir, penelitian ini mengimplementasikan perluasan metode berupa *Repeated Stratified K-Fold Cross Validation* untuk meminimalkan variansi dan memastikan kestabilan model pada data medis yang tidak seimbang. Pendekatan ini dikonfigurasi menggunakan 5 *fold* dengan 3 kali pengulangan acak, sehingga metrik evaluasi akhir merupakan nilai rata-rata dari 15 skenario pengujian yang berbeda.

2.2.12 Threshold Optimization

Pada klasifikasi biner, probabilitas prediksi dikonversi menjadi keputusan kelas menggunakan ambang batas (*threshold*). Penggunaan *threshold default* sebesar 0,5 sering kali tidak optimal pada data tidak seimbang, sehingga diperlukan optimasi batas keputusan (*threshold optimization*) untuk meningkatkan deteksi kelas minoritas [11]. Penelitian ini mengoptimasi *threshold* secara matematis menggunakan fungsi objektif F2-Score guna memberikan bobot lebih besar pada *Recall*. Pendekatan ini secara spesifik memprioritaskan minimalisasi *False*

Negative agar model lebih sensitif dalam mendeteksi pasien stroke. Keputusan klasifikasi setelah proses threshold optimization dapat dirumuskan sebagai berikut:

$$\hat{y} = \begin{cases} 1, & p(x) \geq t \\ 0, & p(x) < t \end{cases}$$

Keterangan:

- $\hat{y}$ = hasil prediksi kelas
- $p(x)$ = probabilitas prediksi model
- t = nilai threshold optimal

Nilai F2-Score dirumuskan sebagai:

$$F_2 = \frac{(1 + 2^2)(Precision \times Recall)}{(2^2 \times Precision) + Recall}$$

atau:

$$F_2 = 5 \frac{Precision \times Recall}{4Precision + Recall}$$

Nilai threshold yang menghasilkan F2-Score tertinggi dipilih sebagai threshold optimal dan digunakan pada tahap evaluasi model akhir.

2.2.13 Explainable Artificial Intelligence (SHAP)

Explainable Artificial Intelligence (XAI) merupakan pendekatan yang digunakan untuk menjelaskan bagaimana model Machine Learning menghasilkan suatu Keputusan. Model ensemble seperti boosting dan stacking memiliki struktur yang kompleks sehingga sulit dijelaskan hanya berdasarkan hasil prediksi [17]. SHAP (*SHapley Additive exPlanations*) merupakan salah satu metode interpretasi yang menghitung kontribusi setiap fitur terhadap hasil prediksi model berdasarkan konsep Shapley Value. Nilai SHAP dapat dituliskan sebagai:

$$f(x) = \phi_0 + \sum_{i=1}^n \phi_i$$

Keterangan:

- $f(x)$: hasil prediksi model
- ϕ_0 : nilai dasar model
- ϕ_i : kontribusi fitur ke-i terhadap prediksi

Dalam penelitian ini, interpretasi SHAP diimplementasikan menggunakan pendekatan dua level untuk meningkatkan transparansi keputusan model. Level pertama (ensemble-level) mengevaluasi besaran pengaruh keluaran probabilitas

model dasar terhadap keputusan akhir meta-learner. Selanjutnya, level kedua (clinical-level) digunakan pada model dasar yang paling dominan untuk mendekonstruksi faktor risiko pasien secara transparan, baik melalui analisis kepentingan fitur secara umum (Global), arah pergeseran probabilitas akibat suatu fitur dominan (Dependence), maupun penjelasan pada tingkat prediksi pasien secara individu (Local) [10].

2.2.14 Evaluasi Performa Model

Evaluasi model bertujuan mengukur kemampuan generalisasi prediksi pada data baru. Pada kasus klasifikasi medis dengan data tidak seimbang, mengandalkan metrik *Accuracy* saja dapat memberikan ilusi performa, karena model cenderung bias memprediksi kelas mayoritas. Oleh karena itu, penelitian ini menggunakan serangkaian metrik komprehensif yang berfokus pada ketepatan keseluruhan dan sensitivitas deteksi kelas stroke [12].

1. **Accuracy:** Mengukur persentase ketepatan prediksi secara keseluruhan. Pada dataset tidak seimbang, metrik ini harus dievaluasi bersama metrik lain agar terhindar dari bias dominasi kelas mayoritas [2].

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Keterangan:

- TP (*True Positive*) = data positif yang diprediksi benar
- TN (*True Negative*) = data negatif yang diprediksi benar
- FP (*False Positive*) = data negatif yang diprediksi sebagai positif
- FN (*False Negative*) = data positif yang diprediksi sebagai negatif

2. **Precision:** Menunjukkan rasio ketepatan prediksi pada kelas positif. Metrik ini digunakan untuk memantau seberapa banyak prediksi stroke dari model yang benar-benar akurat (*False Positive*) [2].

$$Precision = \frac{TP}{TP + FP}$$

3. **Recall:** Mengukur kemampuan model menemukan seluruh data positif aktual. Dalam prediksi stroke, metrik ini sangat krusial karena nilai yang rendah mengindikasikan banyaknya pasien berisiko yang gagal terdeteksi (*False Negative*) [2].

$$Recall = \frac{TP}{TP + FN}$$

4. **F1-Score:** Merupakan rata-rata harmonik dari *Precision* dan *Recall*. Metrik ini digunakan untuk melihat keseimbangan model dalam menangani *False Positive* dan *False Negative* secara bersamaan [2].

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

5. **F2-Score:** Pengembangan dari F1-Score yang memberikan bobot lebih besar pada *Recall*. Penelitian ini menggunakan F2-Score sebagai metrik objektif utama karena sistem difokuskan untuk menekan sekecil mungkin jumlah pasien stroke yang tidak terdeteksi [11].

$$F2 = (1 + 2^2) \frac{Precision \times Recall}{(2^2 \times Precision) + Recall}$$

atau:

$$F2 = 5 \frac{Precision \times Recall}{4Precision + Recall}$$

6. **ROC-AUC:** Mengevaluasi kemampuan model dalam membedakan kelas positif dan negatif pada berbagai pergeseran nilai *threshold*. Semakin tinggi nilainya, semakin baik daya diskriminasi model [2].
7. **PR-AUC:** Metrik evaluasi yang berfokus pada hubungan *Precision* dan *Recall* di berbagai *threshold*. PR-AUC lebih relevan dan andal untuk dataset tidak seimbang karena evaluasinya murni terpusat pada performa kelas minoritas (stroke) [2].
8. **Confusion Matrix:** Tabel matriks yang memetakan distribusi prediksi ke dalam empat kondisi (TP, TN, FP, FN). Analisis ini membantu membedah jenis kesalahan prediksi secara spesifik [2].
9. **Analisis Perbedaan Metrik Evaluasi (Metric Gap):** Analisis perbedaan nilai antar metrik (seperti selisih *Accuracy* dan *Recall*) untuk memahami stabilitas model secara mendalam. Pendekatan ini memastikan tingginya akurasi sejalan dengan kemampuan nyata model dalam mendeteksi kelas minoritas, bukan sekadar menebak kelas dominan [12].

Pemilihan beberapa metrik tersebut dilakukan agar evaluasi tidak hanya melihat performa umum model, tetapi juga kemampuan model dalam mendeteksi kasus stroke.

3. PERANCANGAN SISTEM

3.1 Metodologi Penelitian

Penelitian ini menggunakan pendekatan kuantitatif dengan metode eksperimen untuk mengembangkan model prediksi risiko stroke berbasis *machine learning*. Proses penelitian dilakukan melalui beberapa tahapan yang meliputi pengumpulan data, analisis data eksploratif, prapemrosesan data, pembangunan model *Stacking Ensemble Learning*, optimasi *threshold*, evaluasi performa model, serta interpretasi hasil prediksi menggunakan *SHapley Additive exPlanations* (SHAP). Seluruh tahapan dirancang untuk menghasilkan model prediksi yang tidak hanya memiliki performa yang baik tetapi juga mampu memberikan penjelasan terhadap faktor-faktor yang memengaruhi hasil prediksi.

3.2 Sumber dan Karakteristik Data

3.2.1 Sumber Dataset

Penelitian ini menggunakan data sekunder yang bersumber dari open-source repository Kaggle, secara spesifik menggunakan *Stroke Prediction Dataset*. Dataset ini merupakan representasi rekam medis klinis yang bersifat anonim, berisi parameter kesehatan publik yang digunakan untuk memprediksi kecenderungan seorang pasien terkena serangan stroke berdasarkan faktor demografi, riwayat penyakit, dan kondisi fisiologis. Stroke merupakan penyakit dengan tingkat mortalitas dan disabilitas yang tinggi. Identifikasi dini faktor risiko stroke dapat membantu tenaga kesehatan melakukan tindakan pencegahan sebelum terjadi kejadian stroke aktual. Dataset ini juga memiliki karakteristik:

- kombinasi fitur numerik dan kategorikal
- distribusi kelas tidak seimbang
- data tabular medis

Karakteristik tersebut sesuai dengan permasalahan yang ingin diselesaikan pada penelitian ini.

3.2.2 Dimensi dan Struktur Data

Karakteristik fundamental yang mendasari perancangan eksperimen penelitian ini adalah adanya ketimpangan distribusi kelas (*class imbalance*) pada variabel target *stroke*. Distribusi tersebut menunjukkan bahwa jumlah observasi pada kelas tidak stroke jauh lebih besar dibandingkan kelas stroke sehingga memerlukan strategi pemodelan yang mampu mempertahankan kemampuan deteksi terhadap kelas minoritas.

Table 3 Spesifikasi Atribut Dataset Prediksi Stroke

No	Nama Atribut	Tipe Data	Skala Pengukuran	Deskripsi Atribut & Nilai Kategori
1	<i>id</i>	Numerik (Integer)	Nominal	Identifikator unik untuk setiap pasien (dieliminasi saat pemodelan).
2	<i>gender</i>	Kategorikal (String)	Nominal	Jenis kelamin pasien: <i>Male</i> (Pria), <i>Female</i> (Wanita), dan <i>Other</i> .
3	<i>age</i>	Numerik (Float)	Rasio	Representasi usia biologis pasien dalam satuan tahun.
4	<i>hypertension</i>	Kategorikal (Integer)	Nominal (Biner)	Riwayat penyakit hipertensi: 0 = Tidak memiliki, 1 = Memiliki hipertensi.
5	<i>heart_disease</i>	Kategorikal (Integer)	Nominal (Biner)	Riwayat penyakit jantung: 0 = Tidak memiliki, 1 = Memiliki penyakit jantung.
6	<i>ever_married</i>	Kategorikal (String)	Nominal (Biner)	Status pernikahan pasien: <i>No</i> (Belum/Tidak Menikah) dan <i>Yes</i> (Pernah/Sudah Menikah).
7	<i>work_type</i>	Kategorikal (String)	Nominal	Jenis pekerjaan pasien: <i>children</i> , <i>Govt_job</i> , <i>Never_worked</i> , <i>Private</i> , atau <i>Self-employed</i> .
8	<i>Residence_type</i>	Kategorikal (String)	Nominal	Tipe wilayah tempat tinggal: <i>Rural</i> (Pedesaan) atau <i>Urban</i> (Perkotaan).
9	<i>avg_glucose_level</i>	Numerik (Float)	Rasio	Kadar glukosa atau gula darah rata-rata pasien dalam satuan mg/dL.
10	<i>bmi</i>	Numerik (Float)	Rasio	Indeks Massa Tubuh (<i>Body Mass Index</i>) pasien dalam satuan kg/m ² .
11	<i>smoking_status</i>	Kategorikal (String)	Nominal	Status konsumsi rokok pasien: <i>formerly smoked</i> , <i>never smoked</i> , <i>smokes</i> , atau <i>Unknown</i> .

No	Nama Atribut	Tipe Data	Skala Pengukuran	Deskripsi Atribut & Nilai Kategori
12	<i>stroke</i>	Kategorikal (Integer)	Nominal (Biner)	Variabel Target (Label): 0 = Tidak terkena stroke, 1 = Terdiagnosis stroke.

3.2.3 Analisis Karakteristik Distribusi dan Ketimpangan Kelas (*Class Imbalance*)

Karakteristik utama dataset ini adalah tingginya ketimpangan kelas (*class imbalance*), di mana kelas mayoritas (Tidak Stroke) mencapai 95,13% (4.861 observasi) berbanding kelas minoritas (Stroke) yang hanya 4,87% (249 observasi). Kondisi medis yang timpang ini rentan membuat model bias terhadap kelas mayoritas, sehingga menghasilkan ilusi akurasi yang tinggi namun berakibat fatal pada tingginya angka *False Negative* (pasien stroke yang gagal terdeteksi). Mengingat kegagalan deteksi sangat berbahaya bagi tindak lanjut medis pasien, penelitian ini meminimalkan *False Negative* tersebut menggunakan pendekatan *Recall-Oriented Classification* melalui optimasi ambang batas (*threshold tuning*). Strategi ini berfokus meningkatkan sensitivitas deteksi kasus stroke tanpa harus memodifikasi karakteristik asli data pada tahap pengujian klasifikasi.

3.3 Desain Sistem

Rancangan sistem pada penelitian ini dikembangkan untuk membangun model prediksi risiko stroke berbasis *machine learning* yang mampu menangani karakteristik data kesehatan tidak seimbang serta menghasilkan interpretasi prediksi yang transparan. Sistem dirancang melalui serangkaian tahapan yang terintegrasi mulai dari pengumpulan data, analisis karakteristik data, pembangunan model *Stacking Ensemble Learning*, optimasi keputusan klasifikasi, hingga interpretasi hasil prediksi menggunakan pendekatan *Explainable Artificial Intelligence* (XAI). Arsitektur sistem yang diusulkan terdiri atas enam fase utama yang saling berhubungan. Setiap fase memiliki fungsi spesifik dalam menghasilkan model prediksi yang akurat, sensitif terhadap kasus stroke, serta mampu menjelaskan faktor-faktor yang memengaruhi keputusan prediksi.




Figure 1. Desain Sistem

3.4 Skenario dan Alur Sistem Prediksi

Penelitian ini dirancang melalui enam fase sistematis yang terintegrasi, mulai dari pemahaman karakteristik data hingga interpretasi hasil prediksi secara klinis. Seluruh alur eksperimen dibangun dengan fokus utama pada penanganan data medis yang sangat tidak seimbang (*highly imbalanced*), sehingga pencegahan kebocoran data (*data leakage*) dan optimasi sensitivitas model menjadi landasan pada setiap tahapan.

3.4.1 Fase 1. Eksplorasi dan Pemahaman Data (Exploratory Data Analysis)

Fase ini bertujuan untuk menganalisis karakteristik awal dataset klasifikasi biner risiko stroke sebelum masuk ke tahap pemodelan. Eksplorasi dilakukan untuk memetakan struktur variabel dan mengidentifikasi anomali data. Aktivitas utama pada fase ini meliputi:

1. **Identifikasi Struktur dan Pemilahan Fitur:** Mengekstraksi dimensi data dan mengelompokkan atribut menjadi fitur numerik berkelanjutan (seperti *age*, *avg_glucose_level*, *bmi*) dan fitur kategorikal (seperti *gender*, *smoking_status*, *ever_married*). Pemilahan ini menjadi dasar dalam menentukan fungsi transformasi matematis yang akan diterapkan pada *Pipeline*.
2. **Analisis Karakteristik Missing Value:** Mendeteksi keberadaan data kosong pada dataset. Secara khusus, fitur *bmi* memiliki sejumlah nilai kosong. Mengingat distribusi data fisiologis manusia rentan terhadap pencilan (*outliers*), imputasi tidak menggunakan nilai rata-rata (*mean*), melainkan secara metodologis menggunakan nilai tengah (*median*) agar representasi data tetap kokoh. Nilai kosong pada fitur kategorikal diimputasi menggunakan modus (*most frequent*).
3. **Validasi Ketimpangan Kelas (Class Imbalance):** Memetakan rasio aktual antara kelas mayoritas (pasien non-stroke) dan kelas minoritas (pasien stroke). Validasi empiris atas ketimpangan yang ekstrem ini menjadi justifikasi utama mengapa akurasi konvensional tidak dapat diandalkan dan mengapa diperlukan algoritma penyintesis data. **Output Fase 1:** Profil karakteristik dataset, strategi penanganan data kosong, serta bukti empiris tingkat ketimpangan kelas yang mendasari keputusan metodologis.

3.4.2 Fase 2. Persiapan Data (Data Preparation)

Fase ini adalah lini pertahanan utama untuk menjaga integritas eksperimen. Dataset mentah ditransformasikan menjadi himpunan data yang bersih, berskala seragam, dan seimbang tanpa memicu kebocoran informasi (*data leakage*). Urutan pengerjaannya dieksekusi secara ketat:

1. **Pemisahan Data (Stratified Data Splitting):** Memisahkan dataset sejak awal menjadi 80% data latih (*training set*) dan 20% data uji (*testing set*). Teknik *stratified* memastikan proporsi pasien stroke tetap sama di kedua bagian. Data uji diisolasi sepenuhnya sebagai standar ujian final.
2. **Prapemrosesan Terintegrasi (Pipeline):** Membangun otomatisasi prapemrosesan untuk data latih. Fitur numerik diimputasi dan disamakan skalanya menggunakan *StandardScaler*, sedangkan fitur kategorikal dikonversi menjadi representasi biner melalui *One-Hot Encoding*.
3. **Penanganan Ketidakseimbangan Kelas (SMOTE):** Mengimplementasikan algoritma SMOTE (*Synthetic Minority Oversampling Technique*) untuk menyintesis data pasien stroke. SMOTE dikunci ketat di dalam *Pipeline* agar proses penyeimbangan hanya terjadi secara internal pada data latih dan tidak mencemari data uji. **Output Fase 2:** Himpunan data uji yang terisolasi sempurna dan skema *Pipeline* prapemrosesan yang kebal dari kebocoran data.

3.4.3 Fase 3. Pengembangan Model Prediksi (Model Development)

Fase ini berfokus pada perancangan arsitektur klasifikasi, di mana kinerja arsitektur *Stacking Ensemble* akan dikembangkan dan ditandingkan secara objektif dengan model pembanding tunggal.

1. **Model Pembanding (Baseline):** Menggunakan *Random Forest* sebagai tolok ukur awal untuk memvalidasi apakah penggunaan arsitektur *stacking* yang kompleks benar-benar memberikan peningkatan performa yang signifikan dibandingkan model berbasis pohon keputusan tunggal.
2. **Model Dasar (Base Learners):** Melatih tiga algoritma *Gradient Boosting* yang andal pada data tabular: XGBoost (pencarian pola kompleks), LightGBM (efisiensi komputasi), dan CatBoost (penanganan fitur kategorikal). Pencarian parameter optimal (*hyperparameter tuning*) pada ketiga model ini dieksekusi menggunakan *RandomizedSearchCV* dengan menetapkan **F2-Score sebagai fungsi objektif (*objective function*)**. Pendekatan ini secara spesifik memaksa algoritma dasar agar memprioritaskan sensitivitas deteksi (*Recall*) sejak tahap awal pembelajaran.
3. **Arsitektur Stacking Ensemble:** Ketiga model dasar tersebut dilatih menggunakan metode *cross-validation* guna menghasilkan probabilitas tebakan silang atau *Out-of-Fold* (OOF). Probabilitas ini kemudian digabungkan menjadi fitur baru yang dipelajari oleh *meta-learner* (Logistic Regression). Teknik OOF ini bertujuan memastikan agar *meta-learner* mengambil kesimpulan prediksi akhir dari data yang murni dan tidak bias.

Untuk semakin menekan angka *False Negative*, *meta-learner* diinstruksikan menggunakan **pembobotan kelas (*class weight*)** khusus yang memberikan penalti lebih besar jika model gagal mendeteksi pasien stroke. **Output Fase 3:** Model pembandingan (*Random Forest*) dan arsitektur *Stacking Ensemble* utuh yang siap memproduksi probabilitas prediksi risiko stroke.

3.4.4 Fase 4. Threshold Optimization dan Evaluasi Model

Fase ini bertujuan menentukan ambang batas keputusan (*threshold*) optimal, menggantikan nilai *default* 0.5 yang terbukti berisiko tinggi menghasilkan *False Negative* pada data medis yang timpang.

1. **Menghasilkan Prediksi OOF:** Memproduksi prediksi probabilitas silang menggunakan *Stratified K-Fold Cross Validation* sebagai acuan perhitungan batas keputusan.
2. **Analisis Trade-Off dan Optimasi Threshold:** Model klasifikasi secara bawaan menggunakan ambang batas keputusan (*decision threshold*) 0,5. Pada data medis yang tidak seimbang, penggunaan nilai baku tersebut berisiko tinggi menghasilkan banyak *False Negative*. Oleh karena itu, optimasi *threshold* dilakukan dengan mengevaluasi probabilitas prediksi secara dinamis melalui kurva *Precision-Recall*. Titik *threshold* optimal ditentukan secara matematis berdasarkan pencapaian nilai *F2-Score* tertinggi Guna mencegah penurunan tingkat presisi yang berlebihan akibat trade-off yang ekstrem, diterapkan batasan evaluasi yang ketat guna memastikan model tetap mempertahankan nilai Precision yang logis di antara sekumpulan kandidat batas keputusan yang mendekati nilai *F2-Score* maksimal.
3. **Evaluasi Stabilitas dengan Repeated CV:** Menilai konsistensi performa model secara ketat menggunakan *Repeated Stratified K-Fold Cross Validation* (5-fold dengan 3 repetisi). Pendekatan ini menguji model melewati 15 skenario pembagian data acak yang berbeda.
4. **Pelaporan Metrik Terukur:** Mengkalkulasi metrik *Accuracy*, *Precision*, *Recall*, *Metric Gap* (selisih absolut antara akurasi dan recall untuk mengukur bias), *F1-Score*, *F2-Score*, *ROC-AUC*, dan *PR-AUC*. Hasil evaluasi dilaporkan secara akademis menggunakan format *Mean ± Standard Deviation* untuk membuktikan tingkat kestabilan prediksi.

3.4.5 Fase 5. Pengujian pada Hold-Out Test Set

Fase ini merupakan tahap pembuktian empiris untuk mengukur kemampuan generalisasi arsitektur *Stacking Ensemble* secara utuh. Sesuai dengan prinsip pengujian yang ketat, 20% data uji (*hold-out test set*) yang telah dipisahkan sejak awal (Fase 2) dan belum pernah terpapar proses pelatihan maupun *oversampling*

SMOTE, digunakan secara eksklusif pada tahap ini. Data uji yang murni ini juga akan menjadi basis data utama untuk analisis interpretasi SHAP di fase berikutnya. Rangkaian aktivitas pada fase pengujian ini meliputi:

1. **Pelatihan Final Model Stacking:** Sebelum dihadapkan pada data uji, keseluruhan arsitektur *Stacking Ensemble* (beserta *base learners* dan *meta-learner*) dilatih ulang secara final menggunakan 100% himpunan data latih yang telah melalui tahap prapemrosesan. Hal ini memastikan model menyerap seluruh informasi maksimal yang tersedia dari data pelatihan.
2. **Prediksi Probabilitas Data Uji:** Memasukkan himpunan data pasien baru (*hold-out test set*) ke dalam model yang telah dilatih untuk memproduksi nilai probabilitas risiko stroke secara kontinu (berkisar antara 0 hingga 1).
3. **Penerapan Threshold Klinis:** Nilai probabilitas prediksi tidak dikonversi menggunakan batas *default* 0.5. Probabilitas tersebut dikonversi menjadi keputusan diagnosis biner (0 untuk Non-Stroke, 1 untuk Stroke) dengan menerapkan titik *threshold* optimal berbasis *F2-Score* dan *Precision Guard* yang telah dihitung secara matematis pada Fase 4.
4. **Evaluasi Performa Real-World:** Membandingkan hasil tebakan akhir model dengan label diagnosis yang sesungguhnya pada data uji. Seluruh metrik evaluasi (termasuk *Accuracy*, *Precision*, *Recall*, *Metric Gap*, *F2-Score*, *ROC-AUC*, dan *PR-AUC*) dikalkulasi ulang untuk memverifikasi apakah performa model tetap stabil atau mengalami penurunan (indikasi *overfitting*) saat bertemu data dunia nyata.
5. **Analisis Trade-Off Precision dan Recall:** Melakukan analisis keseimbangan (*trade-off*) secara spesifik pada hasil prediksi data uji. Analisis ini divisualisasikan melalui *Precision-Recall Curve* untuk memvalidasi secara empiris bahwa ambang batas optimal yang dipilih benar-benar mampu mengamankan tingkat deteksi pasien stroke (*Recall*) tanpa mengorbankan ketepatan prediksi (*Precision*) secara berlebihan.
6. **Visualisasi Evaluasi Kinerja:** Menyajikan pemetaan prediksi tambahan untuk memudahkan analisis klinis, yang mencakup pembuatan matriks kebingungan (*Confusion Matrix*) untuk membedah distribusi *True Positive* dan *False Negative*, serta memetakan daya diskriminasi probabilitas model melalui kurva *ROC*.

Output Fase 5: Hasil performa metrik akhir yang objektif beserta visualisasi evaluasi dari model *Stacking Ensemble* pada himpunan data pengujian murni, yang siap digunakan sebagai landasan studi kasus individual pada interpretasi medis.

3.4.6 Fase 6. Explainable Artificial Intelligence (SHAP)

Fase penutup ini bertujuan untuk mendekonstruksi sifat *black-box* dari arsitektur *Stacking Ensemble*. Untuk memastikan hasil klasifikasi dapat

dipertanggungjawabkan secara teknis maupun medis, penelitian ini mengusulkan **Dual-Layer Interpretability Framework** yang terdiri dari dua lapisan interpretasi utama:

1. Layer 1: Algorithmic Validation (Meta-Learner Analysis) Tahap ini merupakan validasi teknis terhadap struktur *stacking*. Menggunakan *LinearExplainer* yang diterapkan pada *meta-learner (Logistic Regression)*, tahap ini bertujuan untuk membedah mekanisme internal sistem. Analisis ini berfungsi untuk memvalidasi secara matematis algoritma dasar (*base learners*) mana yang memberikan kontribusi probabilitas paling signifikan terhadap keputusan akhir, sehingga menjamin bahwa arsitektur ansambel yang dibangun bekerja secara harmonis dan tidak bias.

2. Layer 2: Clinical Diagnostics (Global & Local Analysis) Tahap ini berfokus pada interpretasi hasil diagnosis agar selaras dengan kebutuhan praktisi medis. Menggunakan pendekatan *KernelExplainer* pada model *Stacking* secara keseluruhan (*model-agnostic*), analisis ini dibedah menjadi dua dimensi:

- **Global Clinical Trend (Summary Plot):** Memvisualisasikan pola hubungan antara fitur klinis dengan risiko stroke pada level populasi. Tahap ini bertujuan untuk memvalidasi apakah arah pengaruh fitur (misalnya: korelasi usia atau kadar glukosa terhadap risiko stroke) telah konsisten dengan kaidah medis yang berlaku umum.
- **Local Clinical Insight (Waterfall Plot):** Melakukan dekonstruksi risiko pada level individual pasien. Tahap ini memberikan justifikasi spesifik mengenai alasan medis mengapa profil rekam medis seorang pasien tertentu diklasifikasikan masuk ke dalam zona risiko tinggi, sehingga memberikan informasi yang dapat ditindaklanjuti secara klinis oleh dokter.

Output Fase 6: Terwujudnya transparansi ganda, yaitu transparansi algoritmik untuk validasi sistem dan transparansi klinis untuk validasi diagnosis, yang menjadikan arsitektur *stacking* ini sebagai sistem pendukung keputusan yang akuntabel.

DAFTAR PUSTAKA

- [1] J. Faria, S. M. Azmat Ullah, and M. R. Hasan, "Stroke Detection Through Ensemble Learning: A Stacking Approach," *2024 International Conference on Advances in Computing, Communication, Electrical, and Smart Systems: Innovation for Sustainability, iCACCESS 2024*, 2024, doi: 10.1109/ICACCESS61735.2024.10499584.
- [2] M. Salmi, D. Atif, D. Oliva, A. Abraham, and S. Ventura, "Handling imbalanced medical datasets: review of a decade of research," *Artif Intell Rev*, vol. 57, no. 10, Oct. 2024, doi: 10.1007/s10462-024-10884-2.
- [3] M. Abdelhamid and A. Desai, "Balancing the Scales: A Comprehensive Study on Tackling Class Imbalance in Binary Classification," Sep. 2024, Accessed: Jun. 13, 2026. [Online].
- [4] S. Zian, S. A. Kareem, and K. D. Varathan, "An Empirical Evaluation of Stacked Ensembles with Different Meta-Learners in Imbalanced Classification," *IEEE Access*, vol. 9, pp. 87434–87452, 2021, doi: 10.1109/ACCESS.2021.3088414.
- [5] B. T. Mashi, M. Hamada, J. J. Tanimu, P. Robert, and T. J. Samson, "An Ensemble Approach for Stroke Prediction," *Proceedings - 2024 IEEE 17th International Symposium on Embedded Multicore/Many-core Systems-on-Chip, MCSoc 2024*, pp. 381–388, 2024, doi: 10.1109/MCSOC64144.2024.00069.
- [6] F. Li and G. S. Deede Mintah, "Stroke Prediction Using a Stacked Ensemble Classifier," *ICCIP 2024 - 2024 the 10th International Conference on Communication and Information Processing*, vol. 1, pp. 675–681, May 2025, doi: 10.1145/3708657.3708765;PAGEGROUP:STRING:PUBLICATION.
- [7] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on tabular data?," Jul. 2022, Accessed: Jun. 13, 2026. [Online]. Available: <https://arxiv.org/pdf/2207.08815>
- [8] O. Agafonov, A. Babic, S. Sousa, and S. Alagaratnam, "Editorial: Trustworthy AI for healthcare," *Front Digit Health*, vol. 6, p. 1427233, 2024, doi: 10.3389/FDGTH.2024.1427233.
- [9] L. Hwangbo *et al.*, "Stacking ensemble learning model to predict 6-month mortality in ischemic stroke patients," *Scientific Reports 2022 12:1*, vol. 12, no. 1, pp. 17389–, Oct. 2022, doi: 10.1038/s41598-022-22323-9.
- [10] K. Moulaei, L. Afshari, R. Moulaei, B. Sabet, S. M. Mousavi, and M. R. Afrash, "Explainable artificial intelligence for stroke prediction through

comparison of deep learning and machine learning models,” *Sci Rep*, vol. 14, no. 1, Dec. 2024, doi: 10.1038/S41598-024-82931-5.

[11] X. Zhang, H. Gweon, and S. Provost, “Threshold Moving Approaches for Addressing the Class Imbalance Problem and their Application to Multi-label Classification; Threshold Moving Approaches for Addressing the Class Imbalance Problem and their Application to Multi-label Classification”, doi: 10.1145/3441250.

[12] I. Araf, A. Idri, and I. Chairi, “Cost-sensitive learning for imbalanced medical data: a review,” *Artificial Intelligence Review 2024 57:4*, vol. 57, no. 4, pp. 80-, Mar. 2024, doi: 10.1007/S10462-023-10652-8.

[13] L. A. van de Mortel and G. A. van Wingen, “Data leakage in machine learning studies creep into meta-analytic estimates of predictive performance,” *Mol Psychiatry*, vol. 30, no. 12, pp. 6070–6071, Dec. 2025, doi: 10.1038/S41380-025-03336-Y.

[14] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, vol. 13-17-August-2016, pp. 785–794, Mar. 2016, doi: 10.1145/2939672.2939785.

[15] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T. (2017). Lightgbm: A highly efficient gradient boosting decision tree. *Advances in neural information processing systems*, 30.

[16] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, “CatBoost: unbiased boosting with categorical features,” *Adv Neural Inf Process Syst*, vol. 2018-December, pp. 6638–6648, Jun. 2017, Accessed: Jun. 13, 2026. [Online]. Available: <https://arxiv.org/pdf/1706.09516>

[17] X. Lu and H. Qiu, “Explainable prediction of daily hospitalizations for cerebrovascular disease using stacked ensemble learning,” *BMC Medical Informatics and Decision Making 2023 23:1*, vol. 23, no. 1, pp. 59-, Apr. 2023, doi: 10.1186/S12911-023-02159-7.